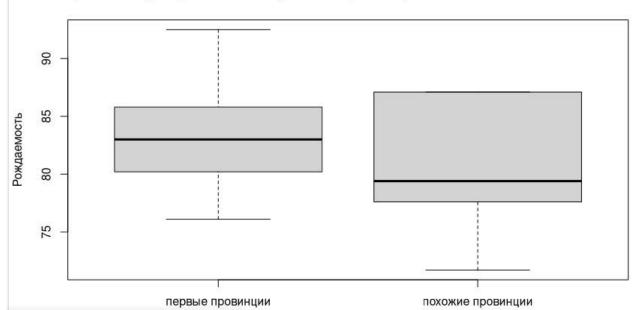


```
# task 2
# 1
initial swiss = swiss
scaled_swiss = cbind(swiss[, 1], scale(swiss[, 2:6]))
base pr = scaled swiss[1:10,]
other pr = scaled swiss[11:47, ]
similar pr = rep(0, 10)
cur_pr = rep(0, 37)
for (i in 1:10){
  b = base_pr[i, 2:6]
  for (j in 1:37){
    cur_pr[j] = dist(rbind(b, other_pr[j, 2:6]), method = "euclidean")
  similar pr[i] = which.min(cur pr)
similar_pr
# 7 25 25 33 7 1 1 1 25 1
# оказалось, что четыре провинции являются ближайшими к нескольким базовым провинциям
x = swiss[1:10, 1]
y = swiss[similar pr + 10, 1]
boxplot(x, y,
        main="Сравнение рождаемости в первых 10 провинциях и 10 самых похожих на них",
        names=c("первые провинции", "похожие провинции"),
        ylab="Рождаемость")
```

Сравнение рождаемости в первых 10 провинциях и 10 самых похожих на них



заметим, что медиана первых провинций попадает в интервал (Q1, Q3) похожих выборок, # но не наоборот. Возможно, группы различаются (нр второе распределение не похоже # на нормальное).

так как у нас две независимых выборки, применим критерий Манна-Уитни

wilcox.test(x, y, paired = T)

V = 40, p-value = 0.2324

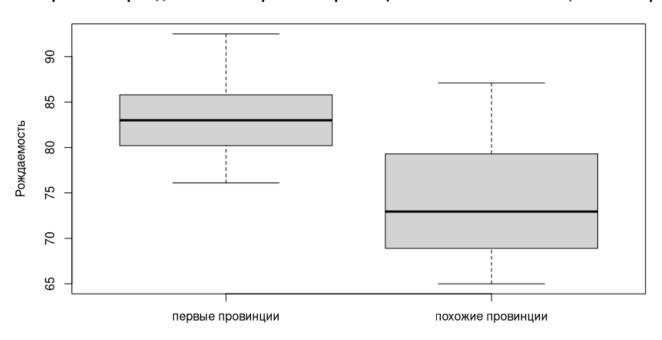
alternative hypothesis: true location shift is not equal to 0

таким образом, нет достаточных оснований отклонить гипотезу о том, что похожи # показатели рождаемости для первых 10 провинций и 10 самых ближайших для них # (по социально-экономическому развитию) провинций на уровне значимости 5%.

```
# попробуем подобрать провинции так, чтобы все провинции были разными cur_dist = matrix(data = 0, nrow = 10, ncol = 37) cur_ind = matrix(data = 0, nrow = 10, ncol = 37)
```

```
for (i in 1:10){
  b = base_pr[i, 2:6]
  for (i in 1:37){
    cur_dist[i, j] = dist(rbind(b, other_pr[j, 2:6]), method = "euclidean")
  cur_ind[i, ] = sort(cur_dist[i, ], index.return=TRUE)$ix
cur_dist[i, ] = sort(cur_dist[i, ], index.return=TRUE)$x
deltas = cbind(cur_dist[, 2] - cur_dist[, 1],
                cur_dist[, 3] - cur_dist[, 2],
                cur_dist[, 4] - cur_dist[, 3],
                cur dist[, 5] - cur dist[, 4])
# руками подбираем вектор индексов (закодить это не смогла, но идея такая, что
# смотрим на таблицы дистанций каждой провинции с каждой, и на такую же таблицу
# индексов, отсортированные по увеличению дистанции. Далее находим разности
# дистанций между первыми эн значений дистанций, чтобы оценить, насколько "дорого"
# обойдется для каждой из первых провинций взять не провинцию с минимальной дистанцией,
# а следующую, чтобы собрать неповторяющиеся провинции).
man_similar_pr = c(7, 28, 25, 33, 4, 16, 24, 1, 26, 20)
y = swiss[man similar pr + 10, 1]
boxplot(x, y,
        main="Сравнение рождаемости в первых 10 провинциях и 10 похожих на них, без повторов",
        names=c("первые провинции", "похожие провинции"),
        ylab="Рождаемость")
```

Сравнение рождаемости в первых 10 провинциях и 10 похожих на них, без повторов



```
# теперь обе медианы не попадают в интервал (Q1, Q3) для других выборок, а # распределение показателей рождаемости стало ближе к нормальному

# так как у нас две независимых выборки, применим критерий Манна-Уитни wilcox.test(x, y, paired = T)

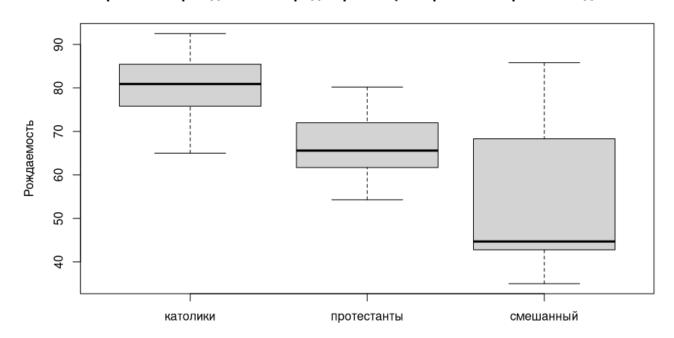
# V = 55, p-value = 0.001953

# alternative hypothesis: true location shift is not equal to 0

# таким образом, если брать неповторяющиеся провинции, отклоняем нулевую гипотезу и о том, что похожи показатели рождаемости для первых 10 провинций и 10 ближайших (по социально-экономическому развитию) провинций на уровне значимости 5% (и даже на уровне значимости меньше 1%).
```

```
# в принципе, разрешить брать повторяющиеся значения для парного сравнения - это нормально,
# и значит, что мы стараемся понять, образуют ли наши данные "хорошие" кластеры, такие, что
# если в п-мерном пространстве отдельной точкой обозначить каждую провинцию, за координаты
# принять значения стандартизованных признаков, а градиентом цвета отобразить целевой признак,
# то рядом окажутся точки примерно одного оттенка. Для того, чтобы взять не повторяющиеся
# провинции, мне понадобилось рассмотреть соседей вплоть до 5-го, и уже для такого рассмотрения
# нам пришлось отклонить нулевую гипотезу о том, что похожи показатели рождаемости, на уровне
# значимости 5%. То есть, по крайней мере при таком выборе основных 10 провинций (с 1 по 10)
# плотность кластеров - около 5 провинций на кластер.
# 2
# соберем католиков, протестантов и смешанную группу в отдельные датасеты
C = c()
P = c()
M = c()
confession = c()
for (i in 1:47) {
  if (initial swiss[i, 5] < 20){
    P = c(P, \overline{i})
    confession = c(confession, 'P')
    else if (initial_swiss[i, 5] > 80) {
    C = c(C, i)
    confession = c(confession, 'C')
  } else
    M = c(M, i)
    confession = c(confession, 'M')
C = initial_swiss[C,
P = initial_swiss[P,
M = initial swiss[M,
initial_swiss = cbind(initial_swiss, confession)
# визуализируем данные по рождаемости
boxplot(C[, 1], P[, 1], M[, 1],
        main="Сравнение рождаемости среди провинций с разным вероисповеданием",
        names=c("католики", "протестанты", "смешанный"),
ylab="Рождаемость")
```

Сравнение рождаемости среди провинций с разным вероисповеданием

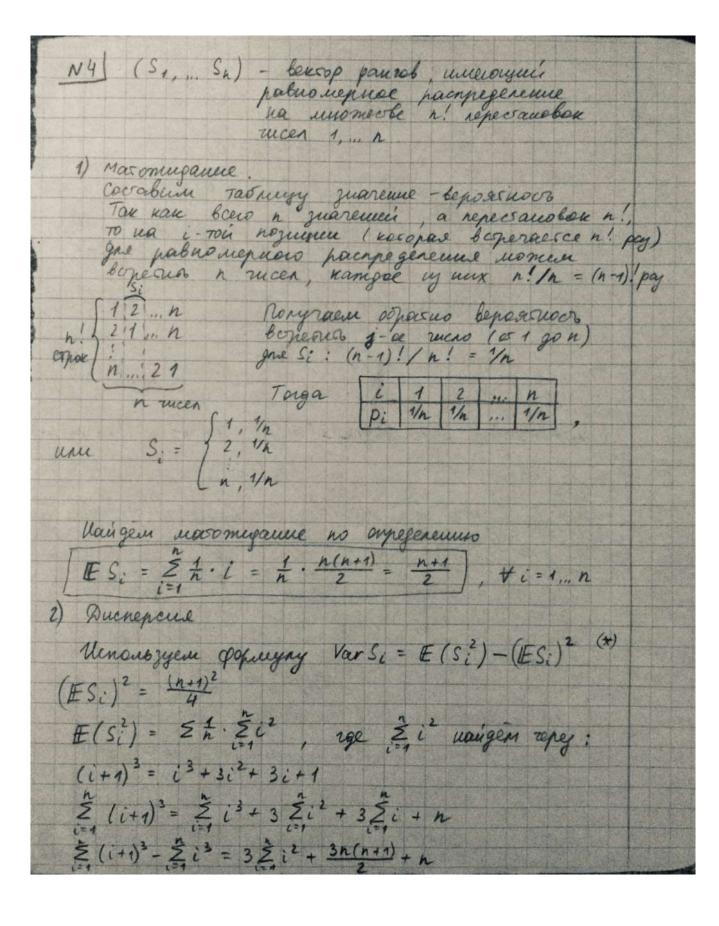


```
# смешанная группа немногочисленная, при этом у нее большой диапазон значений.
# возможно, следовало разделить на две группы и не выделять смешанную группу
# (а может это как раз выбросы из обеих групп - протестантов и католиков).
# все три группы различаются.
# т.к. у нас три независимых группы наблюдений, используем критерий Краскела-Уоллиса
kruskal.test(Fertility~confession, data = initial swiss)
# data: Fertility by confession
# Kruskal-Wallis chi-squared = 18.948, df = 2, p-value = 7.681e-05
# на уровне значимости 5% (и даже меньше 1%) отвергаем нулевую гипотезу о том, что
# во всех трёх группах провинций уровень рождаемости имеет одно и тоже распределение.
# проведем попарные сравнения, для этого снова используем критерий Манна-Уитни
# удалим дублирующиеся значения для каждой пары по отдельности
P[-which((duplicated(c(C[, 1], P[, 1])))) - length(C[, 1]), 1] # 1 значение
wilcox.test(C[, 1], P[-which((duplicated(c(C[, 1], P[, 1])))) - length(C[, 1]), 1],\\
             alternative = "greater")
# W = 372.5, p-value = 1.079e-05
# alternative hypothesis: true location shift is greater than 0
# отклоняем нулевую гипотезу о том, что распределение показателя рождаемости для
# католиков меньше или равно этому показателю для протестантов на уровне значимости
# 5% (даже меньше 1%, порядка 2 тысячных процента)
(duplicated(c(M[, 1], C[, 1]))) # нет дублей wilcox.test(C[, 1], M[, 1], alternative = "greater")
# W = 67, p-value = 0.01248
# alternative hypothesis: true location shift is greater than 0
# отклоняем нулевую гипотезу о том, что распределение показателя рождаемости для
# католиков меньше или равно этому показателю для смешанной категории на уровне
# значимости 5% (даже меньше 2%)
(duplicated(c(M[, 1], P[, 1]))) # нет дублей
wilcox.test(P[, 1], M[, 1], alternative = "greater")
# W = 88, p-value = 0.1175
# alternative hypothesis: true location shift is greater than 0
# нет достаточных оснований отклонить нулевую гипотезу о том, что распределение
# показателя рождаемости для протестантов меньше или равно этому показателю для
# смешанной категории на уровне значимости 5% (даже 10%)
# создаем пустую матрицу для средних значений показателя рождаемости
fert = matrix(data=NA, nrow=4, ncol=3)
# создадим вспомогательную матрицу с граничными значениями
B = matrix(data=NA, nrow=2, ncol=3)
# первая строка - % мужчин, работающих в сельском хозяйстве
B[1, 2] = 50
# вторая строка - 1 квартиль детской смертности по всему датасету
B[2, 2] = quantile(initial swiss[, 6])["25%"]
B[1:2, 3] = 10000
B[1:2, 1] = 0
confessions = c('P', 'C', 'M')
num=1
matr = initial_swiss
 for (i in 1:2){
  for (j in 1:2){
     for (conf in 1:3){
      cond12 = matr[, 2] < B[1, i + 1] & matr[, 6] < B[2, j + 1]
      if (length(ind) > 0){
        fert[num, conf] = mean(initial swiss[ind, 1])
       } else
        fert[num, conf] = median(initial swiss[which(cond12 & cond21), 1])
      }
    num = num + 1
friedman.test(fert)
# Friedman chi-squared = 3.5, df = 2, p-value = 0.1738
# на уровне значимости 5% не имеем достаточно оснований отклонить нулевую гипотезу
# о том, что средний показатель рождаемости в каждой подгруппе одинаков для групп
# с разным соотношением протестантов и католиков, проживающих в провинциях Швейцарии.
```

(Использовали критерий Фридмана, так как групп больше 2, и они не независимы)

```
Teoperus Useinepa - Provinca:
                                     а- некоторае тогна
                                               71
                                          Pac. 1
             monens unepyon
                              cocrebuoa
очество почи д почи постобов
      нахотерия сушил можнов инеризи катдого
   объеков обмостельно тогки а (п.з.1, 3.2), мо вистема
       можетой инеризии отностеньию устра
тамест с составной финуры каторой из облеков финуро.
(1.1, 1.2), a jasem usina nomens unepyun ocel
quight disciserous Torke à (n.2)
                                         TOTEX/05zensol 2)
             bee parnicamine
     mexamile
                 naxongenue yeupa mace puryper
монию зашений на нахотрение нешетического
 vempa (chequee aprix in mire case horismentic
 точек финуры )- бариченра - если предполагаем
      obser oguspogen no mornoca
                     maccy wan manybege une
 10189 hepenemen
 madeon 1 rosum na manurello Torex
            нассу одней тогии равией единице.
           1 = 1 ... Q, i=1 ... con-bo Toren objecta (ew Macca my)
```

 $Torga M = \frac{2}{j=1} m_j = \frac{2}{j=1} \sum_{i=1}^{m_j} m_{ij}$ Перенопине задату на исходите данные задания положения составной финурог отношнения се Πης το χίζ - μορη μιασα ί-τοι τον μι χειορα ενωρα εν Torga komerces torek j-raw od bersa npu egunurusi macce rorum syges pasus mj (nj y naramounx yenobun jaganus), mij=1 K (Q) - nonvecto of benso covabresis queypor Rogorabum bee & copingry (3) \(\langle m; \| \vec{z}_j - \vec{a} \|^2 = \vec{\vec{\vec{z}}} \int mig \| \vec{z}_j - \vec{a} \|^2 = \vec{\vec{\vec{z}}} \vec{\vec{z}} \\ \vec{z}_j - \vec{z}_s \vec{z} \\ \vec{z}_j - \vec{z}_s \vec{z}_s \\ \vec{z}_j - \vec{z}_s \vec{z}_s \\ \vec{z}_s - \vec{z}_s -Zmj 11 = - = = = = mij 11 = = > = = = (xij - xoj) 2 mj 11 c - a 112 = 2 z mij 11 c - a 112 => 5 z = 1 (20j - 20)2 = = [Tax van borpameure nog cymenois ne jabueus et i] = $= \sum_{j=1}^{2} n_{j} (x_{\cdot j} - \chi_{\cdot o})^{2}$ (oбираем всё вместе: $\sum_{j=1}^{2} \sum_{i=1}^{2} (\chi_{ij} - \chi_{\cdot o})^{2} = \sum_{j=1}^{2} \sum_{i=1}^{2} (\chi_{ij} - \chi_{\cdot o})^{2} + \sum_{j=1}^{2} n_{j} (\chi_{oj} - \chi_{\cdot o})^{2}$



 $(n+1)^3-1=3\sum_{i=1}^{n}i^2+\frac{3n(n+1)}{2}+n$ $-\frac{2}{3}i^{2} = \left(\frac{3n(n+1)}{3} + (n+1) - (n+1)^{3}\right) \cdot \frac{1}{3} =$ $i = {}^{1}(3n+2-2(n+1)^{2})(n+1) = (n+1)(-2n^{2}-4n-2+2+3n) = {}^{1}$ $= -h(2n+1)(n+1) => \frac{2}{2}i^2 = \frac{h(n+1)(2n+1)}{6}$ Nogerabnirem $6c\bar{e}$ 8 bornamenne gane guenepenne (*)

Var Si = $\frac{1}{n}$, $\frac{n(n+1)(2n+1)}{6} - \frac{(n+1)^2}{4} = \frac{2(2n^2+n+2n+1)}{12}$ $-\frac{3(n^2+2n+1)}{12} = \frac{4n^2-3n^2+6n-6n+2-3}{12} = \frac{n^2-1}{12} = Var Si$ 3) Kobapua yune cov(Si, Sj) = ESiSj - ESi ESj (**) (6 cury uneinocre nacomugame, ru. wikipedia org/wki/kosarnayus) $ES_i = ES_j = \frac{n+1}{2}$, ranga $ES_i \cdot ES_j = \frac{(n+1)^2}{4}$ первое сначаение намодем с помощью тобмини, где в сремах запишем значение Si, а в стелочех-Sj Tax kax un pacerca probaen

1 1.1 1.2 ... 1.n cryrais i * j , 70

2 2.1 2.2 ... 2.n un mem nocrusar cynny

h n.1 n.2 ... n.n borrecro granousususe

mareume = i 2

mareume = i 2 Сушие всех значений в таблице: 1. (1+2+,,,+h) + 2. (1+2+,,+h)+,,+h. (1+2+,,+h) = $= \sum_{i=1}^{n} i \cdot \sum_{i=1}^{n} i = \frac{n^{2}(n+1)^{2}}{4}$ Супше истромить нам значений: " 1 2 (n+1)2 - n(n+1)(2n+1)

Torga un omniganne IES. Sj - cyumo na beparanour naugreur kamegys napy, n gne parlus mepusos painpegene und sa Bepart noir ogunanola gne Boek h(n-1) memeusob (n-1 7. k my kamegoù my n copon yopann ogus guanouant nel zuarenne). $ES_{i}S_{j} = \left(\frac{h^{2}(n+1)^{2}}{4} - \frac{h(n+1)(2n+1)}{6}\right) \cdot \frac{1}{h(n-1)} =$ $= \frac{3n(n+1)^2 - 2(n+1)(2n+1)}{12(n-1)} = \frac{(n+1)(3n^2 + 3n - 4n - 2)}{12(n-1)} = \frac{(n+1)(3n^2 - n - 2)}{12(n-1)} = \frac{(n+1)(3n+2)(n-1)}{12(n-1)} = \frac{(n+1)(3n^2 + 3n - 4n - 2)}{12(n-1)} = \frac{(n+1)(3n^2 + 3n - 4n - 4n - 2)}{12(n-1)} = \frac{(n+1)(3n^2 + 3n - 4n - 4n - 2)}{12(n-1)} = \frac{(n+1)(3n^2 + 3n - 4n - 4n - 2)}{12(n-1)} = \frac{(n+1)(3n^2 + 3n - 4n - 4n - 2)}{12(n-1)} = \frac{(n+1)(3n^2 + 3n - 4n - 4n - 2)}{12(n-1)} = \frac{(n+1)(3n^2 + 3n - 4n - 4n - 2)}{12(n-1)} = \frac{(n+1)(3n^$ Собирани вогратения для ковариации (++) $ESiSj - IESi \cdot IESj = \frac{(3n+2)(n+1)}{12} - \frac{(n+1)^2}{4} = \frac{(n+1)(3n+2-3n-3)}{12}$ $= \frac{(n+1)\cdot(-1)}{12} = \left[\frac{-(n+1)}{12} = cov(Si,Sj) \right], \ \forall i,j=1...n, i \neq j$

